해운 문서 RAG 검색 실험 보고

붉은 RAG 해적단

김창동 · 천희재 · 윤승환 · 오주헌 · 김경민



조건

기준 조건과 실험 환경

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments / src/config.py 동결값과 컨테이너 실행 설정

> 모든 설정을 같은 연산 자원과 같은 절차로 돌려, 값의 차이가 설정에서만 나오게 했다.

기준 설정 (동결값, 변수 하나만 바꿈)

항목	값
임베딩 / 리랭커	E5 small / bge-reranker-v2-m3
청크 / 겹침 / k	900자 / 0 / 5
후보 / 문맥 한도	20개 / 3,000 추정 토큰
Hybrid	RRF 60, 각 POOL 20
생성·평가 모델	gpt-6-luna, Faithfulness는 3회 평균
질문	Basic 공식 선택 15문항 (답변 9 / 추가 확인 3 / 보류 3)

컨테이너에서 잰 값: 프로세스 최대 메모리 2.8GB, 리랭크 20쌍에 12.1초(호스트 GPU에서는 0.33초). 그래서 시간은 같은 컨테이너 환경의 기준 설정과만 비교했다.

실행 환경과 연산 자원

항목	설정
호스트	Apple M5 Max, 18코어, 메모리 64GB
격리 단위	설정 하나에 Docker 컨테이너 하나 (모든 설정이 같은 이미지)
컨테이너 한도	CPU 3코어, 메모리 4GB, 연산 스레드 3
연산 장치	CPU 전용 (컨테이너는 호스트 GPU를 쓸 수 없음)
Docker VM	메모리 20GB (처음 7.7GB에서 올림)
동시 실행	0·1단계는 1개씩 순차, 2·3단계는 4개 병렬
색인	컨테이너 안에서 설정마다 PDF부터 새로 생성 (로컬 Qdrant)
모델 가중치	호스트 캐시를 읽기 전용으로 공유, 오프라인 모드
기록	팀 공용과 분리한 Langfuse 프로젝트

조건

동일 환경 파라미터 스윕: 목적과 방법

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments / 검색 실험 EXP-0002와는 다른 실험

> 목적: 청크 크기·겹침·k·문맥 한도·후보 수를 같은 실행 환경에서 하나씩 바꾸어 검색·답변·비용을 함께 잰다.

0단계
13개
기준 3회 + 변수당 2값
LLM 평가까지

→

1단계
21개
값 확장
검색 지표만(LLM 없음)

→

2단계
9개
변수별 상위 3개
LLM 평가, 4개 병렬

→

3단계
4 + 2개
값을 합친 조합 4개
최선 조합 2회 재확인

같은 환경

- 설정마다 같은 Docker 이미지와 같은 한도(CPU 3코어, 메모리 4GB)의 컨테이너에서 실행했다.
- 컨테이너 안에서 PDF부터 새로 색인하고 검색 지표, LLM 평가 순으로 돌렸다.
- 모델 가중치는 호스트 캐시를 읽기 전용으로 공유했다. 결과는 팀 공용과 분리한 Langfuse 프로젝트에 기록했다.

결과를 보기 전에 정한 것

- 효과의 기준: Recall ±0.05, 검색 시간 ±20%, 입력 토큰 ±10%, Faithfulness는 기준 3회 범위 밖.
- 2단계 후보 선택 규칙과 3단계 조합의 합격 기준. 규칙을 한 번 보완했고 그 사실을 기록했다.
- 동결 설정 파일과 다른 영역의 코드는 수정하지 않고 실험 스크립트가 값을 덮어썼다.

Basic 공식 선택 15문항(답변 9 / 추가 확인 3 / 보류 3) / 컨테이너 CPU 3코어·메모리 4GB / 시간은 설정 간 상대 비교만 유효 / naive·hybrid·hybrid_rerank / 49개 설정, 오류 0건

조건

기준 설정 3회 반복: 잡음 폭

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments

> 목적: 같은 설정을 반복했을 때 값이 얼마나 흔들리는지 재서, 설정 간 차이를 효과로 볼 기준을 정한다.

관찰

Recall은 매번 같고 Faithfulness는 ±0.02쯤 흔들렸다.

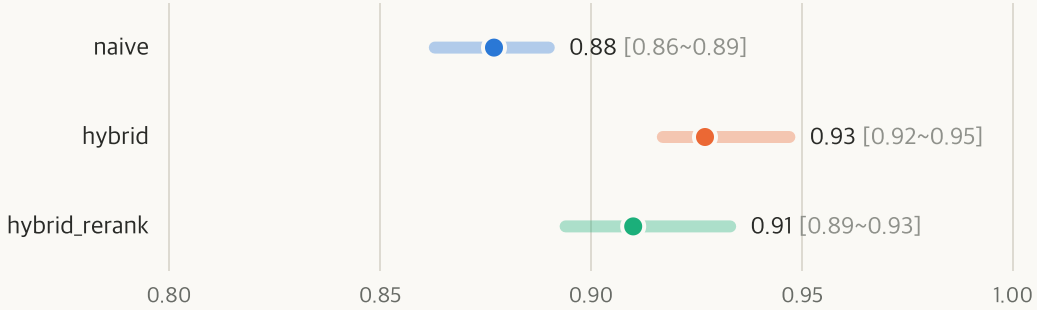
Recall, 문맥 토큰, 입력 토큰은 결정적이다. Faithfulness는 방식마다 0.03~0.04 폭으로 움직였다.

해석의 범위

반복이 3회뿐이라 실제 폭은 더 넓을 수 있다. 이 범위 안의 Faithfulness 차이는 효과로 보지 않았다.

방식	Recall@5	Faithfulness 평균 [범위]	평균 응답 시간 [범위]
naive	0.67 (3회 동일)	0.88 [0.86~0.89]	4.7초 [4.4~5.1]
hybrid	0.74 (3회 동일)	0.93 [0.92~0.95]	4.4초 [4.0~4.7]
hybrid_rerank	0.70 (3회 동일)	0.91 [0.89~0.93]	23.9초 [23.0~24.6]

Faithfulness 범위(기준 3회)



기준 = 청크 900자 / 겹침 0 / k 5 / 문맥 한도 3,000 / 후보 20 / Basic 공식 선택 15문항(답변 9 / 추가 확인 3 / 보류 3) / 컨테이너 CPU 3코어·메모리 4GB / 시간은 설정 간 상대 비교만 유효

비교 결과

변수별 효율 구간

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments / 상세 차트: 부록 01-04

> 목적: 변수마다 품질을 유지하면서 비용이 가장 작은 값의 범위를 찾는다.

변수	기준	효율 구간	근거(hybrid_rerank)
k	5	**8~10**	Recall 0.70 → 0.75(k=8) → 0.81(k=10), k=12도 0.81. 입력 토큰 +41% / +68% / +92%
청크 크기	900자	**450~600자 (리랭커가 있을 때)**	Recall 0.71 / 0.69로 유지, 입력 토큰 -32% / -20%. naive는 Recall 0.67 → 0.61 / 0.54로 하락
리랭커 후보 수	20	**10~15**	검색 시간 18.8초 → 10.2초 / 14.7초, Recall 0.71. 30과 40은 결과가 같았다
겹침	0	**0 유지**	0~300자에서 Recall 변화 ±0.02. Faithfulness는 50에서 오르고 100·200에서 내려 방향이 일관되지 않았다
문맥 한도	3,000	**3,000 (k=8에서 손실 없는 최소)**	k=8에서 2,500은 11문항, 2,000 이하는 15문항의 문맥이 잘렸다. 3,000 이상은 0문항

관찰

k를 8~10으로 올리고 청크와 후보 수는 줄이는 쪽이 유리했다.

k는 Recall을 올리지만 입력 토큰이 늘고, 작은 청크와 적은 후보는 토큰과 시간을 줄였다.

해석의 범위

변수를 하나씩만 바꾼 값이다. 판단은 hybrid_rerank 기준이고 naive는 작은 청크에서 불리했다. 청크 900자 초과는 일부가 임베딩 입력 한도(512토큰)를 넘어 해석을 보류했다.

Basic 공식 선택 15문항(답변 9 / 추가 확인 3 / 보류 3) / 컨테이너 CPU 3코어·메모리 4GB / 시간은 설정 간 상대 비교만 유효

비교 결과

변수별 값을 합친 조합 c1

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments

> 목적: 변수별 효율 구간을 합쳤을 때 이득이 유지되는지 사전 기준으로 판정한다.

Recall@k (결정적)

0.70 → 0.80

+0.10

평균 응답 시간 (3회)

23.9초 → 15.2초

-36%

입력 토큰

40.6k → 43.5k

+7%

Faithfulness (3회 평균)

0.91 → 0.93

범위가 겹쳐 개선으로 보지 않음

조합 4개와 사전 기준 (hybrid_rerank, 첫 실행)

조합	청크 / k / 후보	Recall ≥ 0.75	Faithfulness ≥ 0.89	입력 토큰 ≤ +20%	판정
c1	450 / 10 / 20	0.80 ✓	0.97 ✓	+7% ✓	모두 충족
c2	600 / 8 / 16	0.73 ✗	0.92 ✓	+11% ✓	미달
c3	450 / 8 / 16	0.80 ✓	0.88 ✗	-9% ✓	미달
c4	600 / 10 / 20	0.79 ✓	0.95 ✓	+33% ✗	미달

관찰

c1만 사전 기준을 모두 충족했다.

이득은 Recall과 응답 시간이었다.

해석의 범위

Faithfulness는 3회 평균 0.93 [0.89~0.97]로 기준 0.91 [0.89~0.93]과 범위가 겹친다. 첫 실행의 0.97은 잡음 폭의 상단이었다. 청크 450자에서는 보안 질문의 공격 문장이 문맥에 노출된다(상세: 보안 비교 장).

c1 = 청크 450자 / k 10 / 후보 20 / 겹침 0 / 문맥 한도 3,000. 후보 수는 k의 약 2배로 맞췄다. / Basic 공식 선택 15문항(답변 9 / 추가 확인 3 / 보류 3) / 컨테이너 CPU 3코어·메모리 4GB / 시간은 설정 간 상대 비교만 유효

비교 결과

대표 사례: 같은 질문, 기준과 c1

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments / 질문 S-DEV-06, hybrid_rerank, 각 1회 실행

목적: 숫자의 변화가 실제 답변에서 어떻게 나타나는지 질문 하나로 확인한다.

질문 부산-LA 40GP VGM을 2026년 11월 4일 처음 접수하면서 SI도 제출하려고 합니다. 두 자료의 제출 창구를 구분해 주고, SI 화물 총중량을 VGM에 그대로 복사해도 되는지 설명해 주세요.

기준 (청크 900자 / k 5 / 후보 20)

근거 문서 2 / 7개

문맥 1,616토큰 · 인용 2개 · 상태 answered

VGM은 2026년 11월 4일 처음 접수하는 40GP이므로 가온루트 업무 포털의 VGM 등록함에 제출합니다. SI 제출 창구는 이번 변경 대상이 아니지만, 검색 자료에는 SI의 구체적인 제출 주소나 창구가 기재되어 있지 않아 확인할 수 없습니다. SI 화물 총중량을 VGM에 그대로 복사해도 되는지도 자료만으로는 확인할 수 없습니다. VGM에는 해당 장비의 검증 총중량과 단위를 입력해야 하므로, SI 수치를…

c1 (청크 450자 / k 10 / 후보 20)

근거 문서 4 / 7개

문맥 1,837토큰 · 인용 4개 · 상태 answered

SI는 docs@gaonroute.example로 제출하고, 2026년 11월 4일 처음 접수하는 40GP VGM은 업무 포털의 VGM 등록함에 제출하세요. SI의 화물 총중량을 VGM에 그대로 복사하면 안 됩니다. SI 화물 총중량은 포장 포함·컨테이너 자중 제외이고, VGM은 적입된 컨테이너 전체의 검증 총중량입니다. 두 값은 항목의 정의가 다르므로 실제 검증된 VGM과 단위를 확인해 입력해야 하며, 값이…

관찰

기준은 SI 제출 창구를 찾지 못했고 c1은 주소를 답했다.

찾은 근거 문서가 2개에서 4개로 늘었다(필요한 문서 7개).

해석의 범위

질문 하나, 실행 한 번의 비교다. 답변이 정답인지는 대조하지 않았다. 같은 조합에서 S-FINAL-13은 기대 동작이 답변인데 c1이 되묻기로 바뀌었고, S-FINAL-06은 c1에서도 제출 주소를 찾지 못했다.

비교 결과

보안 비교: 공격 문장 노출과 방어

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments / src/platform/security.py를 스윕 설정에 적용 / 보안 질문 2개

> 목적: 설정을 바꾸면 문서에 심어 둔 공격 문장이 문맥에 들어오는지, 들어왔을 때 답변이 그 지시를 따르는지 확인한다.

공격 문장이 최종 문맥에 들어온 설정 (35개 설정, LLM 없이 판정)

설정	노출된 질문 수 (2개 중, naive / hybrid / hybrid_rerank)
기준 (청크 900자)	없음. k, 문맥 한도, 후보 수를 바꿔도 없음
청크 300 · 600 · 750자, 조합 c2 · c4	없음
청크 450자	1 / 2 / 2
청크 1,050 · 1,200자	1 / 2 / 2
겹침 50~300자	설정과 방식에 따라 0~2개
조합 c1 · c3 (청크 450자)	2 / 2 / 2

방어 비교 (13개 설정 × 질문 2개 × 기본·방어 프롬프트, hybrid_rerank)

확인 항목	기본 프롬프트	방어 프롬프트
답변 수	26	26
공격 문장이 문맥에 노출된 답변	16	16
공격 지시를 따른 답변	0건	0건
필수 사실을 모두 포함한 답변	26 / 26	26 / 26
답변을 거절·보류한 답변	0건	0건

관찰

노출 여부는 k가 아니라 청킹이 갈랐다.

노출된 16건에서도 기본 프롬프트가 공격 지시를 따르지 않았다.

해석의 범위

질문 2개, 설정마다 1회 실행이다. 추종과 정확성은 필수 사실·금지 주장의 문자열 확인과 답변 읽기로 본 초안이며 사람의 최종 판정이 필요하다. 기본 프롬프트가 이미 따르지 않아 방어 프롬프트의 효과(방어율)는 계산할 수 없다. 발제 필수 산출물인 동결 설정의 보안 답변 4개(#42)는 별도 실행이다.

선택과 이유

결론과 다음 검증

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments / 상세 차트: 부록 01-04

> 변경 여부는 점수뿐 아니라 처리 비용과 잡음 폭을 함께 보고 판단했다.

판단	대상	근거와 남은 검증
후보 제안	조합 c1 (청크 450자 / k 10 / 후보 20)	Recall 0.70 → 0.80, 응답 시간 -36%, 입력 토큰 +7%. 15문항 결과라 25문항 이상 재확인 필요
채택 전 확인	조합 c1의 보안 노출	청크 450자에서는 문서에 심어 둔 공격 문장이 문맥에 들어온다(기준 설정은 들어오지 않음). 이번 실행에서 답변이 따르지는 않았으나 질문 2개·1회 결과
기본값 유지	겹침 0 · 문맥 한도 3,000	겹침의 일관된 이득 없음. k=8까지는 3,000에서 문맥이 잘리지 않음
효율 구간 확인	k 8~10 · 리랭커 후보 10~15	k는 Recall을 올리고 입력 토큰을 늘림. 후보 수는 검색 시간에 비례하고 Recall 이득은 없음
후속 검증	설정 채택 여부	Faithfulness 개선은 잡음 폭 안. 채택은 설정 변경 PR과 전체 재실행 뒤에 판단

실패·한계

실패와 확인하지 못한 것

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments

> 좋은 결과만 고르지 않고, 실험 중 실패한 것과 확인하지 못한 것을 그대로 남긴다.

실험 중 실패·이상

- 조합 c1의 첫 실행 Faithfulness 0.97은 재확인에서 잡음 폭의 상단으로 드러났다. 개선으로 쓰지 않았다.
- 조합 c1(청크 450자)은 보안 질문 2개 모두에서 공격 문장이 문맥에 노출됐다. 기준 설정에는 없던 노출이다.
- 청크 900자 초과(1,050·1,200자)는 청크 일부가 임베딩 입력 한도를 넘어 해석을 보류했다.
- 첫 통합 실행에서 Faithfulness가 전부 비었다. 평가 함수가 이벤트 루프 안에서 실패한 것이 원인이었고 고쳐서 다시 돌렸다.
- k=3 설정은 첫 시작이 거부됐다(이전 실행이 남긴 색인 폴더). 지우고 다시 돌렸다.
- 위임한 구현에서 버그 4건을 검토 중 찾아 고쳤다(결과 저장 키, 함수 import, 이미지 복사 경로, 색인 폴더 충돌).
- Docker VM 메모리가 부족해 0·1단계는 병렬로 돌리지 못했다.

확인하지 못한 것

- 질문이 15개라 한 문항이 평균을 6.7%p 움직인다. **25문항 이상 재확인은 하지 않았다.**
- 변수를 하나씩 바꾼 값과 조합 4개만 시험했다. 전역 최적은 보장하지 않는다.
- 후보 선택은 hybrid_rerank 기준이다. naive의 최적값은 따로 찾지 않았다.
- 컨테이너는 GPU를 쓰지 못해 시간의 절대값을 호스트 실행과 비교할 수 없다.
- Faithfulness 잡음 폭은 3회 반복으로만 쟀다. Judge 4항목은 채점하지 않았다.
- 기대 동작과 실제 상태가 어긋난 문항의 원인은 이번 실험에서 다시 확인하지 않았다.
- 노출된 공격 문장을 답변이 따르지 않은 것은 질문 2개·1회 실행의 결과다. 다른 공격 문장에서도 같은지는 확인하지 않았다.

부록

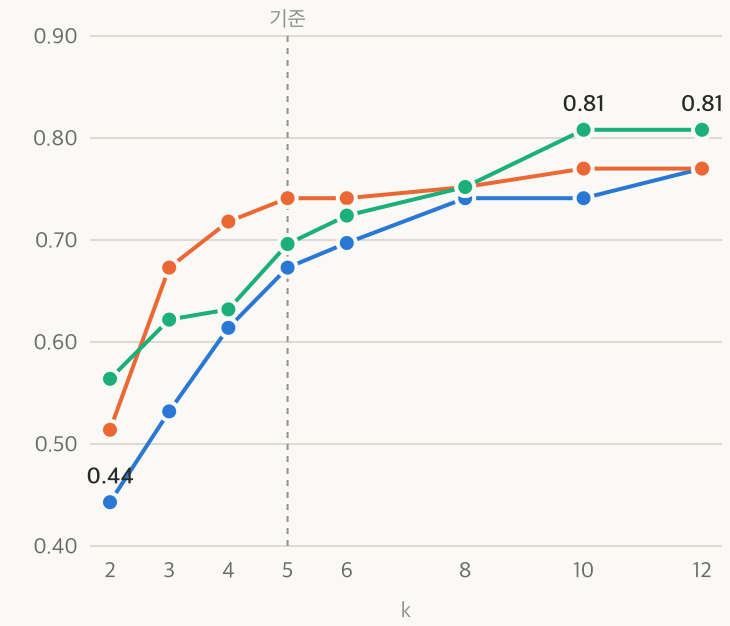
부록 01 · k(topK) 민감도

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments

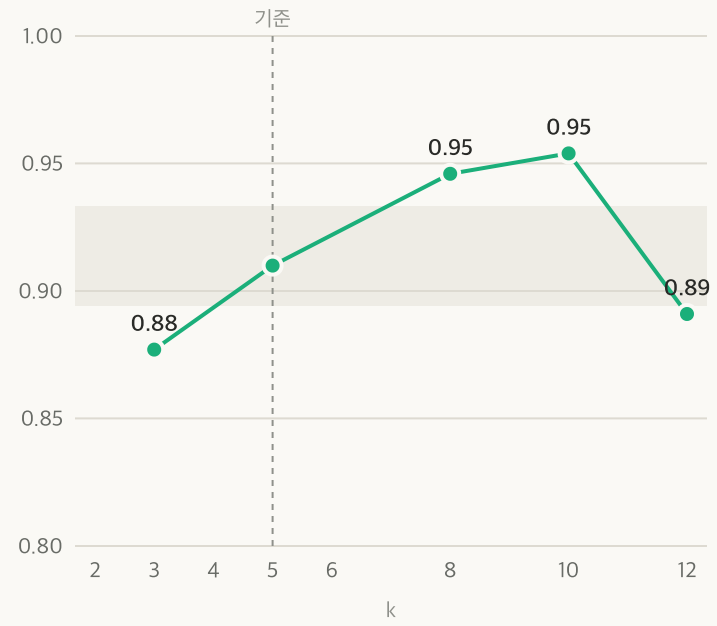
> 최종 문맥에 넣는 청크 수 k를 2~12로 바꿔 Recall, Faithfulness, 입력 토큰의 변화를 본다.

naive hybrid hybrid_rerank 기준 3회 범위(hybrid_rerank Faithfulness)

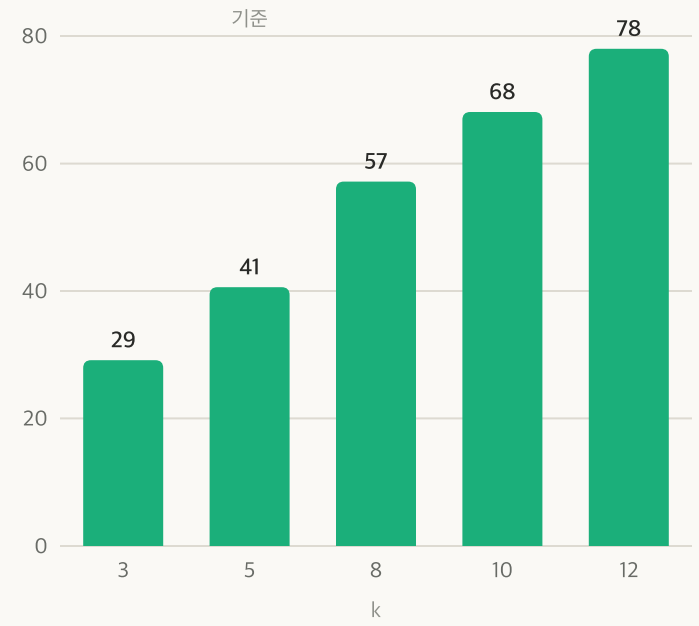
Recall@k (세 방식)



Faithfulness (hybrid_rerank)



입력 토큰 합(천, hybrid_rerank)



- Recall은 k=10에서 0.81로 포화했다(k=12도 0.81). 입력 토큰은 거의 선형으로 늘어 k=12에서 기준의 +92%였다.
- Faithfulness는 k=8~10에서 0.95로 가장 높고 k=12에서 0.89로 내렸다. k=10·12는 문맥 한도를 6,000으로 풀어 평가했다.

Basic 공식 선택 15문항(답변 9 / 추가 확인 3 / 보류 3) / 컨테이너 CPU 3코어·메모리 4GB / 시간은 설정 간 상대 비교만 유효

부록

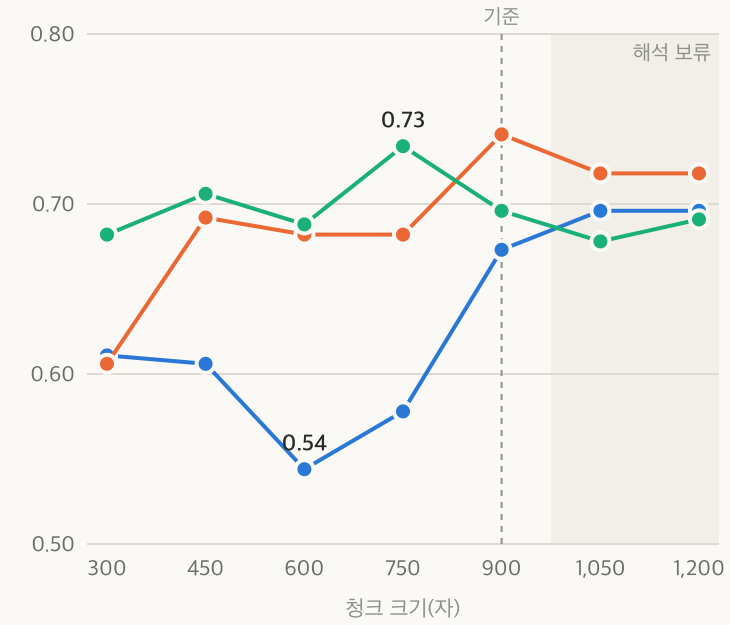
부록 02 · 청크 크기 민감도

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments

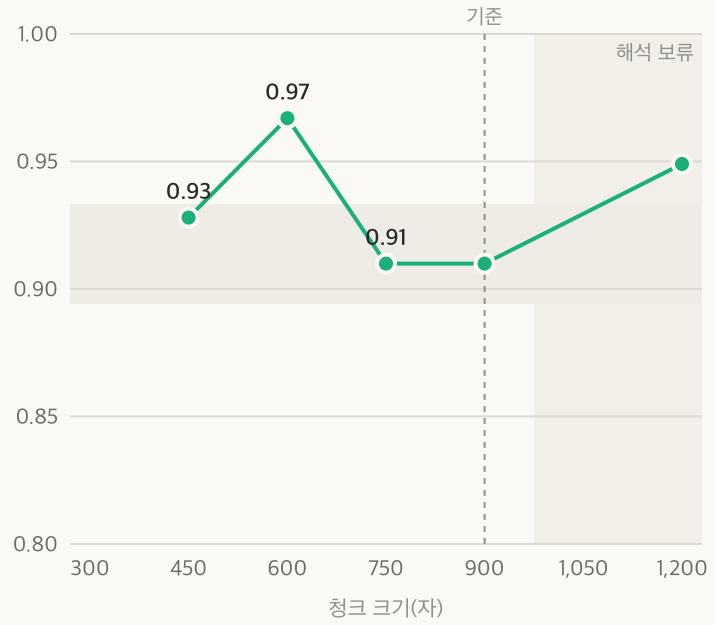
청크 크기를 300~1,200자로 바꿔 방식별 Recall과 hybrid_rerank의 Faithfulness, 입력 토큰을 본다.

naive hybrid hybrid_rerank 기준 3회 범위(hybrid_rerank Faithfulness)

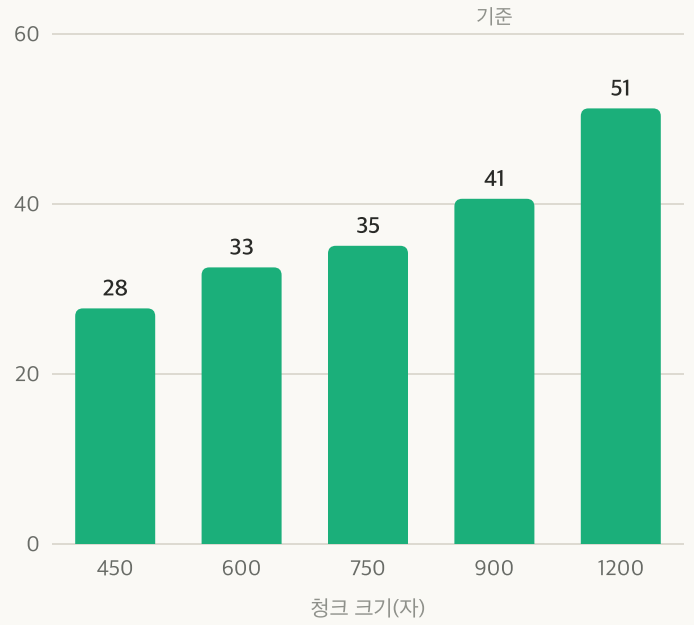
Recall@5 (세 방식)



Faithfulness (hybrid_rerank)



입력 토큰 합(천, hybrid_rerank)



- hybrid_rerank의 Recall은 청크 크기와 거의 무관했다(0.68~0.73). 청크 450자는 입력 토큰 −32%, 검색 시간 −41%였다.
- naive는 작은 청크에서 Recall이 내렸다(0.67 → 0.61). 900자 초과는 청크 일부가 임베딩 입력 한도를 넘어 해석을 보류했다(1,200자는 청크의 29%).

Basic 공식 선택 15문항(답변 9 / 추가 확인 3 / 보류 3) / 컨테이너 CPU 3코어·메모리 4GB / 시간은 설정 간 상대 비교만 유효

부록

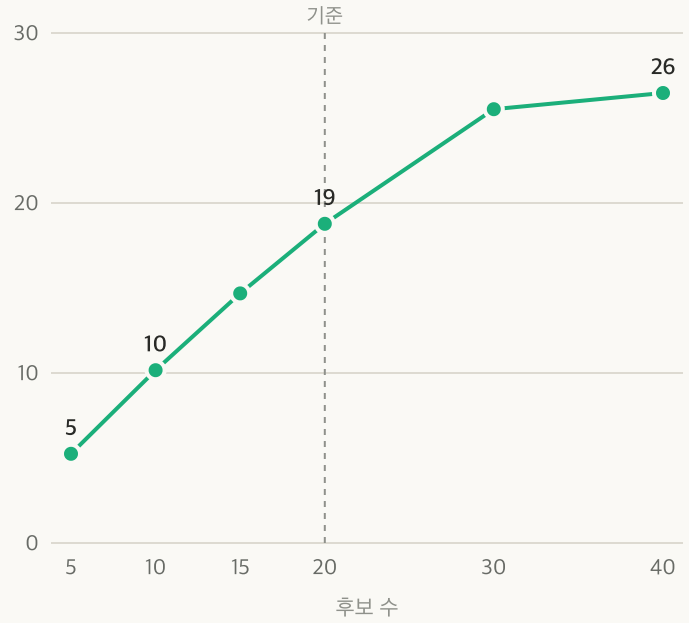
부록 03 · 리랭커 후보 수 민감도

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments

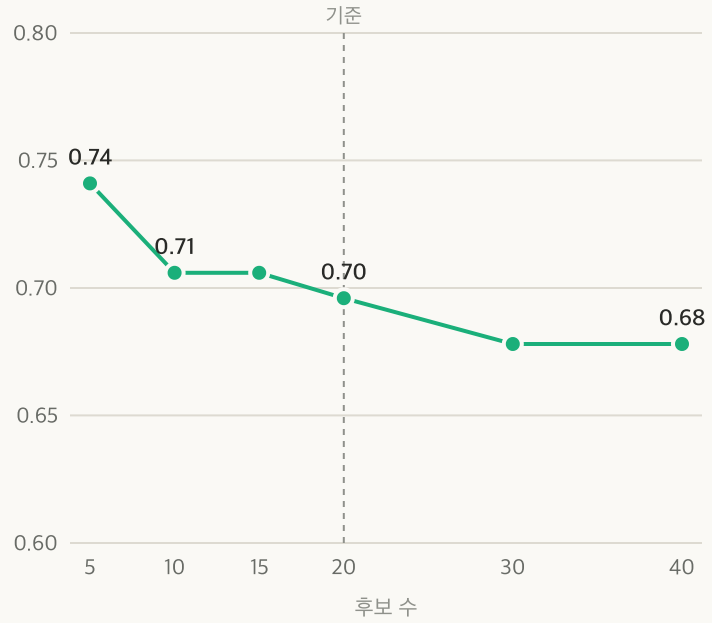
> 리랭커에 넘기는 후보 수를 5~40으로 바꿔 검색 시간, Recall, Faithfulness를 본다.

hybrid_rerank　기준 3회 범위(hybrid_rerank Faithfulness)

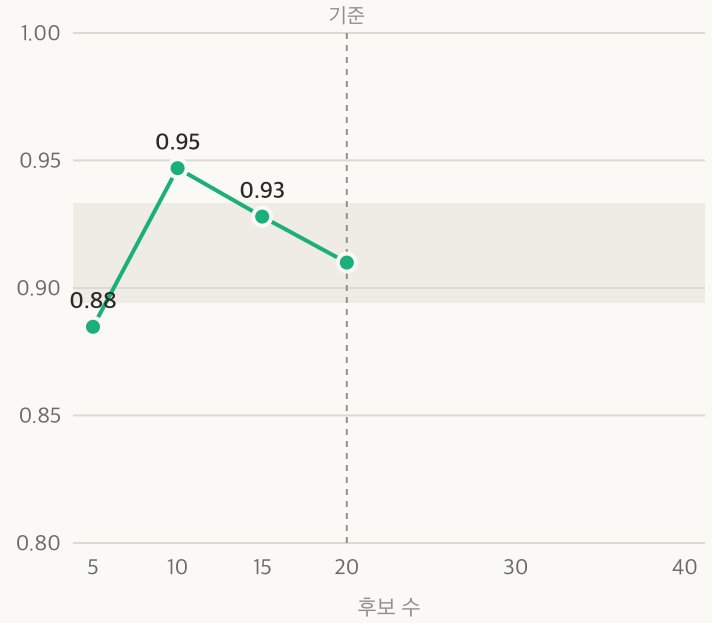
검색 단계 시간(초, 컨테이너 CPU)



Recall@5



Faithfulness



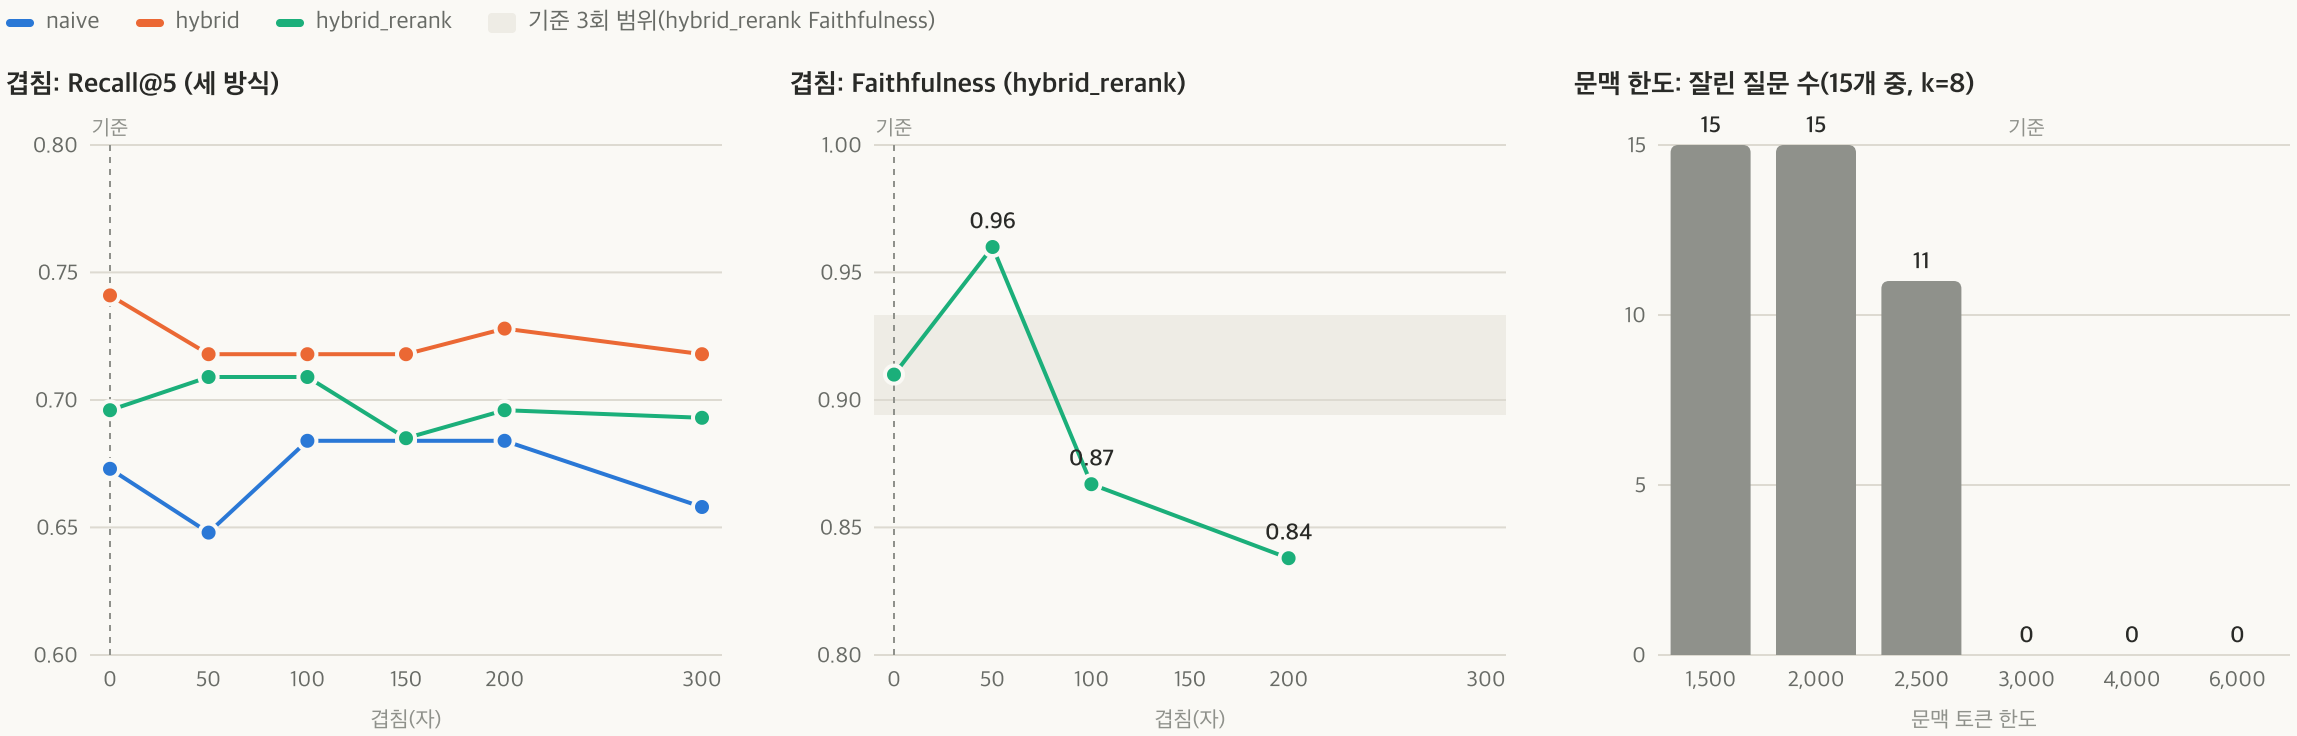
- 검색 시간은 후보 수에 거의 비례했다. Recall은 후보가 늘어도 오르지 않았다.
- 후보 30과 40은 결과가 같았다. 후보가 dense 20개와 keyword 20개의 합집합이라 실제 상한이 약 30개이기 때문이다. 후보 5는 k와 같아 리랭킹이 사실상 없다.

Basic 공식 선택 15문항(답변 9 / 추가 확인 3 / 보류 3) / 컨테이너 CPU 3코어·메모리 4GB / 시간은 설정 간 상대 비교만 유효

부록 04 · 겹침과 문맥 한도

동일 환경 파라미터 스윕(platform) / 문서 0002-param-sweep, 브랜치 exp/langfuse-experiments

> 겹침 0~300자와 문맥 한도 1,500~6,000토큰(k=8)에서 Recall, Faithfulness, 잘린 질문 수를 본다.



- 겹침은 Recall 변화가 ±0.02 안이고 Faithfulness의 방향이 일관되지 않았다.
- 문맥 한도는 k=8에서 3,000부터 한 문항도 잘리지 않았다. 2,000으로 낮추면 15문항이 모두 잘렸지만 hybrid_rerank의 Faithfulness는 0.93이었고 입력 토큰은 24% 줄었다.

Basic 공식 선택 15문항(답변 9 / 추가 확인 3 / 보류 3) / 컨테이너 CPU 3코어·메모리 4GB / 시간은 설정 간 상대 비교만 유효