해운 문서 RAG 검색 실험 보고

붉은 RAG 해적단

김창동 · 천희재 · 윤승환 · 오주헌 · 김경민



조건

기준 조건과 평가 지표

src/config.py / docs/specs/search.md / 각 EXP의 실제 비교 조건

문서 검색

Hit·Recall

근거 포함

그룹 충족·쪽+인용문

생성과 운영

답변 품질·행동·시간

각 표의 Base는 해당 실험에서 실제로 사용한 기준이다.

사전 목표가 없는 실험에는 임의의 합격 수치를 붙이지 않았다. 충분 판정은 답변 정답률과 구분한다.

항목	프로젝트 기본값
임베딩 / 리랭커	E5 small / bge-reranker-v2-m3
청크 / 겹침 / k	900자 / 0 / 5
후보 / 문맥 한도	20개 / 3,000 추정 토큰
Hybrid	RRF 60, E5:BM25 = 1:1, 각 POOL 20

비교 결과

청크 크기 비교

EXP-0002 / 상세 표: 부록 02

> 목적: 근거 문맥을 유지하면서 검색 성능을 확보할 청크 크기를 찾는다.

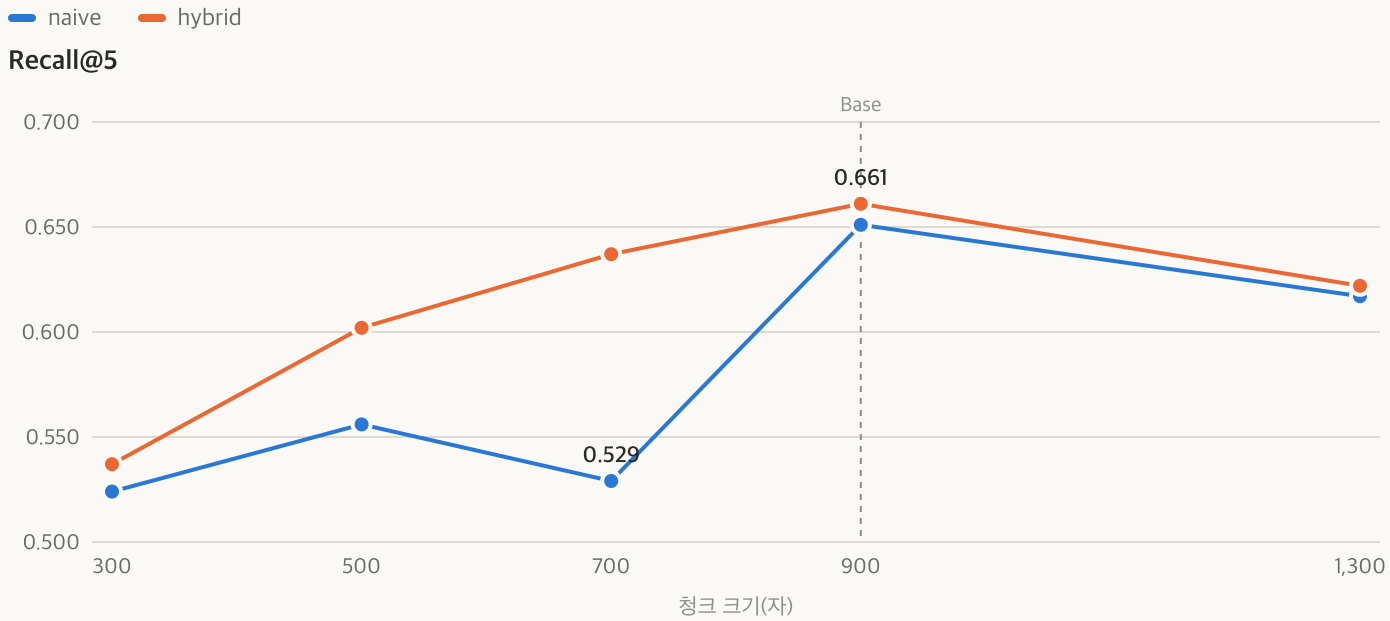
관찰

900자에서 두 방식의 Recall이 가장 높았다.

이 조건에서는 900자 기준을 유지할 근거가 있었다.

해석의 범위

당시 K=5로만 비교한 점이 아쉽다. K별로 크기를 함께 비교했다면 결과가 유지되는지 확인할 수 있었다. 겹침도 0으로 고정했다.



청크(자)	300	500	700	900	1,300
naive Recall	.524	.556	.529	.651	.617
hybrid Recall	.537	.602	.637	.661	.622

Base 900자 / 크기만 변경 / Basic 개발용 / K=5, 겹침=0

비교 결과

리랭커 후보 수 비교

EXP-0004 / 상세 표: 부록 05

> 목적: 후보를 크게 늘리면 빠졌던 근거 문서가 들어오고 Recall도 크게 오르는지 확인한다.

관찰

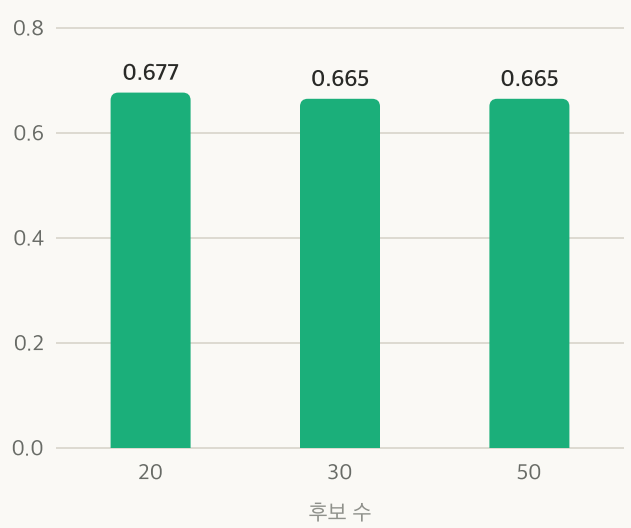
후보 50개에서도 Recall 개선은 관찰되지 않았다.

기대와 달리 최종 k=5의 Recall은 오르지 않았다. 후보 20개를 유지했다.

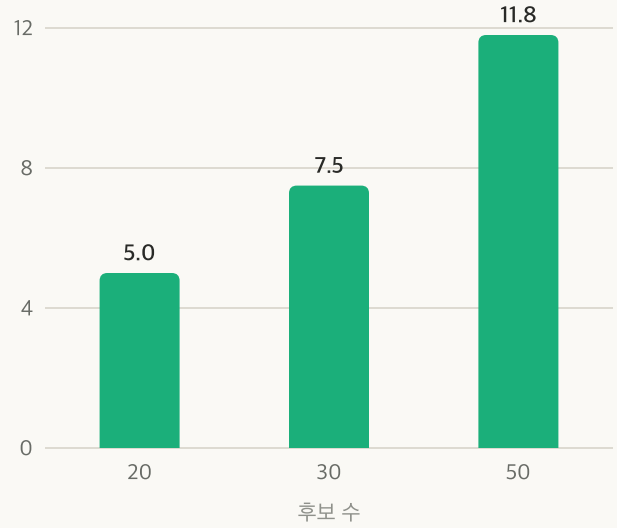
해석의 범위

이 표는 후보 안의 근거 포함률이 아닌 최종 k=5 Recall이다. 후보 확대와 최종 근거 선정의 효과를 구분해야 한다.

Recall@5



질문당 CPU 시간(초)



후보	Recall	질문당 CPU 시간
20 (Base)	.677	5.0초
30	.665	7.5초
50	.665	11.8초

Base 후보 20개 / 30·50개 비교 / Basic, k=5 / CPU 시간

비교 결과

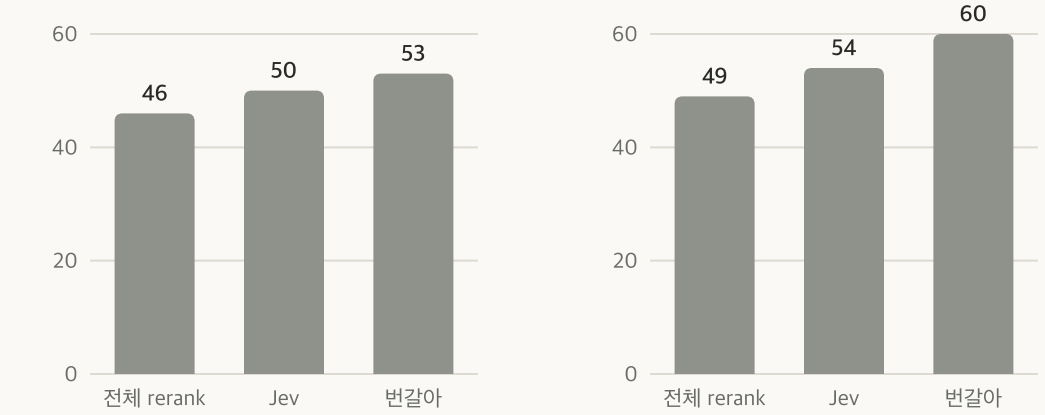
하위 질문별 번갈아 선정의 절차와 지연

EXP-0009 / 충분 판정과 지연은 서로 다른 데이터셋·조건

> 목적: hybrid로 모은 후보에서 선정 방식만 바꾸어 하위 질문의 근거가 빠지는지 확인한다.

단계	처리 방식
1. 질문 분해	LLM이 질문을 최대 4개의 하위 질문으로 나눈다.
2. 후보 수집	하위 질문마다 hybrid 검색 후 RRF로 후보 50개 병합(S).
3. 선정 비교	같은 후보에 전체 질문 rerank, Jev(LLM 판정), 번갈아 적용.
4. 번갈아 선정	하위 질문마다 로컬 rerank한 뒤 Q1 1위, Q2 1위,Q1 2위… 순서로 중복을 건너뛰며 k개를 채운다.

Basic / 같은 S 후보 50개 / 충분 판정 문항 수



지연 증가

1.52초 → 9.59초

평균 +8.07초 / 약 6.3배 · Advanced 60문항, 후보 50개

기존 rerank 대비 O 번갈아

하위 질문 생성 시간 제외

LLM 분해 약 3.3초는 별도 6문항 표본. 생성까지 포함한 중앙값은 약 14초로 추정했다.

Basic의 품질표와 조건이 다르다. Jev와의 동일 조건 지연 비교는 없다. 순위 선정 자체는 로컬 처리다.

비교 결과

청킹을 고정한 k 효과

EXP-0024 / 저장 결과 재분석

> 목적: 크기와 겹침을 고정하고 k 증가의 효과를 분리한다.

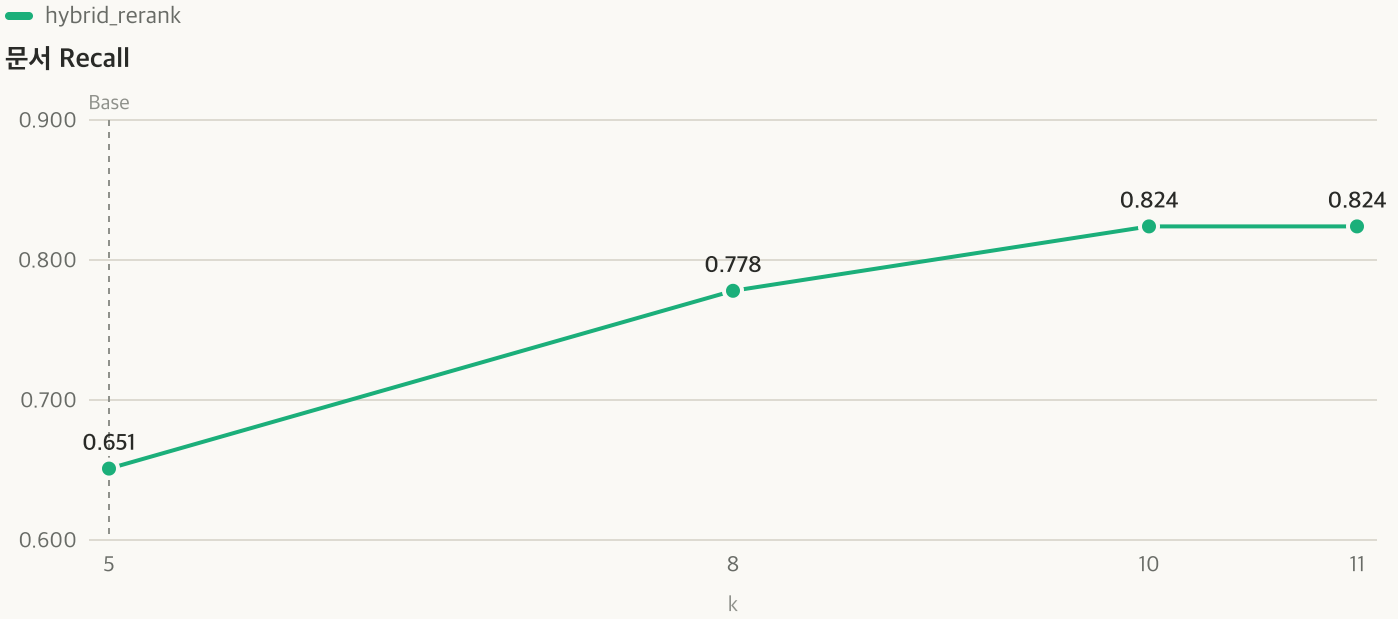
관찰

k를 높이면
더 많은 문서가 포함돼
Recall도 높아졌다.

k=5의 0.651에서 k=10의 0.824로 증가했다. 청킹 개선만의 효과로 해석할 수 없었다.

해석의 범위

최고 청킹을 사후 선택해 재분석했다. 확정 청킹 900자·0%의 k=5 Recall은 0.653이다.



k	5 (Base)	8	10	11
문서 Recall	.651	.778	.824	.824

rerank 800자·겹침 10% 고정 / 문맥 한도 3,000 / 근거 56문항

비교 결과

문서 검색 성공 후의 근거 누락

EXP-0024 / 상세 표: 부록 15

> 목적: book_id뿐 아니라 page와 quote까지 맞는 근거를 찾았는지 확인한다.

관찰

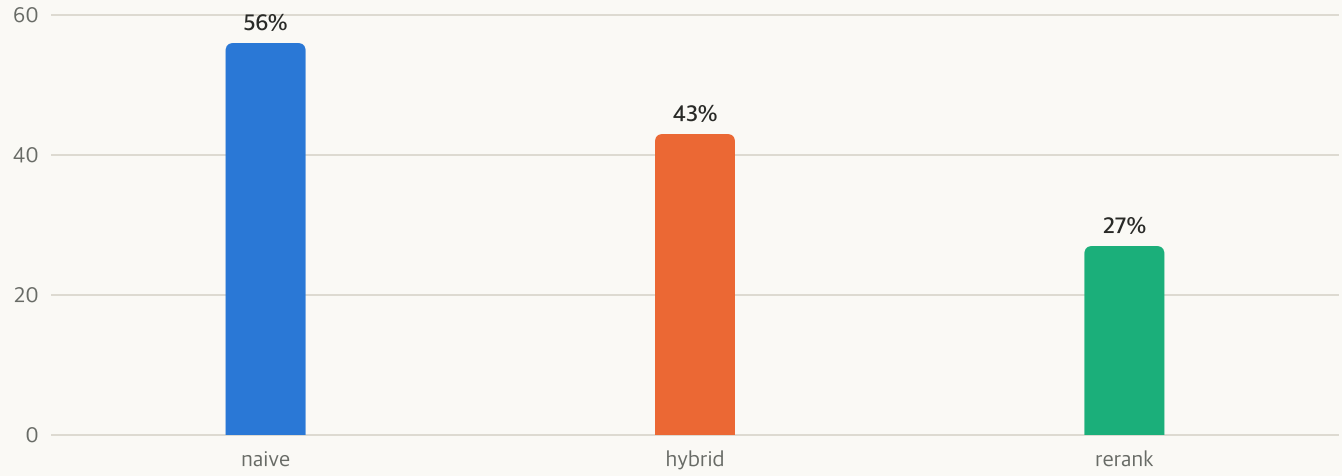
rerank도 30문항 중 8문항에서 정확한 근거를 놓쳤다.

기존 문서 Recall은 book_id를 기준으로 센다.
page·quote까지 확인하면 필요한 근거를 실제로 찾았는지 더 엄격히 볼 수 있다.

해석의 범위

쪽+인용문 모든그룹 충족은 문서 Recall과 다른 진단 지표다.
이 그래프는 그 실패 비율이며 전체 오답률은 아니다.

문서 Recall=1.0 문항 중 근거 그룹 실패 비율



방식	문서 Recall=1.0	그중 근거 그룹 실패
naive	25문항	14문항 (56%)
hybrid	30문항	13문항 (43%)
rerank	30문항	8문항 (27%)

Basic 근거 56문항 중 문서 Recall=1.0인 문항만 분석 / EXP-0014 저장 결과 재분석 / naive 600자·10%·k=11 / hybrid 800자·0%·k=11 / rerank 800자·10%·k=10, 후보 22개 / 문맥 한도 3,000토큰

선택과 이유

결론과 다음 검증

프로젝트 실험 문서 종합 / 상세 비교는 부록 01-17

> 변경 여부는 점수뿐 아니라 근거 포함과 처리 비용을 함께 보고 판단했다.

판단	대상	근거와 남은 검증
기본값 유지	모델·초기 청킹·후보 수	비용 증가를 정당화할 일관된 개선을 확인하지 못함
방식 반영	하위 질문별 번갈아 선정	동일 후보에서 충분 문항 증가. 새 질문 검증 필요
효과 분리	청크 크기·겹침·k	같은 청킹에서도 k 증가로 Recall 개선
후속 검증	문맥 한도·답변 행동	근거 탈락과 되묻기·보류 오류를 별도 점검

실패·한계

실패와 확인하지 못한 것

각 실험 장의 '해석의 범위'를 한 장에 모음 / 문구는 원문 그대로

> 좋은 결과만 고르지 않고, 실험마다 확인하지 못했거나 해석을 제한한 점을 그대로 남긴다.

실험	확인하지 못했거나 해석을 제한한 점
청크 크기 비교 (EXP-0002)	당시 K=5로만 비교한 점이 아쉽다. K별로 크기를 함께 비교했다면 결과가 유지되는지 확인할 수 있었다. 겹침도 0으로 고정했다.
리랭커 후보 수 비교 (EXP-0004)	이 표는 후보 안의 근거 포함률이 아닌 최종 k=5 Recall이다. 후보 확대와 최종 근거 선정의 효과를 구분해야 한다.
하위 질문별 번갈아 선정의 절차와 지연 (EXP-0009)	LLM 분해 약 3.3초는 별도 6문항 표본. 생성까지 포함한 중앙값은 약 14초로 추정했다. Basic의 품질표와 조건이 다르다. Jev와의 동일 조건 지연 비교는 없다. 순위 선정 자체는 로컬 처리다.
청킹을 고정한 k 효과 (EXP-0024)	최고 청킹을 사후 선택해 재분석했다. 확정 청킹 900자·0%의 k=5 Recall은 0.653이다.
문서 검색 성공 후의 근거 누락 (EXP-0024)	쪽+인용문 모든그룹 충족은 문서 Recall과 다른 진단 지표다. 이 그래프는 그 실패 비율이며 전체 오답률은 아니다.
추가 질문에서 검색 방식 재검증 (EXP-0010)	작은 문항 수의 탐색 비교다. 추가 질문에서도 재현되었다고 모든 우위를 주장할 수 없다.
검색 최고 설정의 실제 답변 품질 (EXP-0014)	최고 설정을 사후 선택했다. reference·질문 생성 수 등 공식 채점과 다른 근사 조건이다.
문맥 토큰 한도 확대 검증 (진행 중) (EXP-0020)	현재 표는 후속 실험의 배경 수치다. 한도 확대의 효과와 최종 채택값은 아직 확정하지 않았다.

부록

부록 01 · 임베딩 모델의 데이터셋별 비교

EXP-0001 / Basic 및 Advanced 발췌 / 모두 k=5

> 목적: 문서 구성이 다른 데이터셋에서도 모델 교체의 이득이 유지되는지 확인한다.

종합 판단

품질과 속도를 함께 보면 small이 가장 적합했다.

Basic에서 모델 크기·계열을 비교하고 Advanced에서도 재확인했다. 일관된 교체 이득이 없어 small을 유지했다.

해석의 범위

일부 Recall은 다른 모델이 근소하게 높다. 모든 문서에서 small이 최고라는 뜻은 아니다. Intermediate는 미측정이다.

Basic / naive / 900자 / k=5

항목	small	base	large
Recall@5	0.651	0.611	0.588
색인 시간	35초	71초	209초
질문 임베딩	7ms	20ms	69ms

Advanced / hybrid / k=5 / 확정 청킹

모델	개발용 Recall	추가 Recall	색인(초)
E5 small	.626	.598	119
E5 base	.595	.589	334
bge-m3	.632	.575	1,062

부록

부록 02 · 청크 크기 비교

EXP-0002 / 결과, Basic 크기×첫 줄 / 원문 표 발췌

> 근거 문맥을 유지하면서 검색 성능을 확보할 청크 크기를 찾는다.

결과 해석

900자에서 두 방식의 Recall이 가장 높았다.

300자는 각각 0.524, 0.537이었다.

Basic의 900자 기준을 유지했다. 청크를 작게 나누는 것 자체가 개선은 아니었다.

해석의 범위

K=5, 겹침=0만 비교한 점이 아쉽다. 청크 크기와 K·overlap을 함께 바꿔 확인했어야 한다.
이후 격자 실험은 부록 13에서 별도로 다룬다.

Base / 변경 변수

900자 / 300·500·700·1,300자 비교, k=5·겹침 0 고정

측정 지표

naive·hybrid의 Hit@5와 Recall@5 · Basic 개발용

청크 상한(자)	naive Hit / Recall	hybrid Hit / Recall
300	0.929 / 0.524	0.929 / 0.537
500	0.893 / 0.556	0.964 / 0.602
700	0.893 / 0.529	1.000 / 0.637
900	0.964 / 0.651	1.000 / 0.661
1300	0.964 / 0.617	1.000 / 0.622

부록

부록 03 · 청크 겹침 효과 검증

EXP-0002 / 결과, Basic 겹침 / 원문 표 발췌

> 경계 근거 보완의 이득과 중복 청크로 인한 검색 손실을 확인한다.

결과 해석

겹침 200자에서 hybrid Recall이 0.661에서 0.584로 낮아졌다.

겹침 0 유지. 경계 보완만큼 상위 k개의 중복 점유도 고민해야 했다.

해석의 범위

k=5에서만 겹침을 비교했다. 더 큰 k도 추가했다면 중복 청크의 영향과 겹침 효과가 달라지는지 확인할 수 있었다.

Base / 변경 변수

겹침 0자 / 100·200자 적용, 크기 900자·k=5 고정

측정 지표

문서 Recall@5 · 보조 진단: 상위 k개 안의 같은 쪽 중복 수

겹침(자)	naive Recall	hybrid Recall
0	0.651	0.661
100	0.632	0.660
200	0.620	0.584

부록 04 · Hybrid 파라미터의 최종 검색 효과

EXP-0003 / 결과, Advanced 무게·조각 / 원문 표 발췌

> hybrid에서 유리한 설정이 rerank 이후에도 개선을 유지하는지 검증한다.

결과 해석

E5 무게 0.4는 기본 0.5보다 개발용 Recall이 낮고 추가 질문에서는 같았다.

공통 파라미터 유지. 중간 단계의 이득만 보고 전체 설정을 바꾸지 않았다.

해석의 범위

작은 차이는 노이즈 가능성이 있다. 작은 POOL=10의 rerank 효과는 별도 미측정이다.

Base / 변경 변수

E5 무게 0.5·2-gram / 무게 0.4·2+3 조각 비교, 후보 20 고정

측정 지표

개발용·추가 질문 Recall@5와 문서 모든그룹 충족률 · Advanced

E5 무게	BM25 조각	개발용 R / 그룹	추가 R / 그룹
0.5	2-gram (baseline)	.756 / .448	.626 / .310
0.4	2-gram	.721 / .414	.626 / .310
0.5	2+3	.767 / .483	.635 / .310
0.4	2+3	.759 / .483	.644 / .310

부록

부록 05 · 리랭커 후보 수 비교

EXP-0004 / 결과, Basic 후보 수 / 원문 표 발췌

> 후보를 크게 늘려 낮은 순위의 근거 문서까지 후보 안에 들어오는지 확인한다.

결과 해석

후보를 늘리는 것만으로 필요한 근거를 모두 확보하지는 못했다.

Advanced는 후보 단계의 누락도 남았다. Basic 표의 최종 Recall만으로 후보 누락을 단정하지 않는다.

해석의 범위

낮은 순위로 후보에 들지 못한다는 해석은 누락 진단이다. 모든 데이터셋의 병목이 같다는 뜻은 아니다.

설정·지표 설명

후보 밖의 근거는 rerank로 복구할 수 없다. Advanced 개발용에서는 후보를 20→50개로 늘려도 후보 안 문서 모든그룹 충족률이 .552로 같았다. 후보 안에 있지만 최종 k에서 밀리는 문제도 별도로 있었다.

Basic / 청크 900자·겹침 0 / hybrid_rerank / k=5 / 후보 20·30·50개

후보	Recall	모든그룹(문서)	질문당(CPU)
20	.677	.857	5.0초
30	.665	.821	7.5초
50	.665	.821	11.8초

부록

부록 06 · 문서 Recall과 근거 그룹 충족률 비교

EXP-0007 / 결과, 근거 그룹 OR 정정 / 원문 표 발췌

> 공식 Recall의 낮은 값이 필수 근거 부족을 뜻하는지 진단한다.

결과 해석

hybrid의 공식 Recall은 0.661이지만 그룹 충족률은 0.929였다.

문서 Recall에 그룹 충족과 쪽·인용문 진단을 추가했다.

해석의 범위

그룹 충족도 문서 단위다. 정확한 문장 포함 여부와 최종 답변 품질을 별도로 봐야 한다.

설정·지표 설명

같은 검색 결과에 평가 기준만 바꿨다. 공식 Recall은 정답 book_id 합집합을 기준으로 센다. 근거 그룹은 OR로 연결된 대체 문서 중 하나를 찾으면 충족하며, 모든 그룹 충족은 필요한 그룹이 전부 채워진 문항의 비율이다.

Basic 개발용 28문항 / E5 small / 청크 900자·겹침 0 / k=5 / naive·hybrid

방식	공식 Recall	그룹 충족률	모든 그룹 충족 문항
naive	0.651	0.923	0.857
hybrid	0.661	0.929	0.821

부록

부록 07 · LLM 관련도 채점의 품질·지연 비교

EXP-0008 / 결과, 5.56·5.57절 발췌 / 원문 표 발췌

> 관련도 채점의 검색 이득이 외부 호출 시간과 비용을 감수할 수준인지 확인한다.

결과 해석

LLM 점수 방식은 Recall이 올랐지만 후보 50개를 읽는 데 평균 17초가 걸렸다.

LLM 관련도 채점을 제외했다. 근거 분배를 바꾸는 더 저렴한 방법을 찾았다.

해석의 범위

Recall은 개발용·추가 각 28문항. 시간은 별도 5문항 표본이며 후보 수와 호출 방식이 달라 동일 조건 속도 순위로 볼 수 없다.

설정·지표 설명

LLM 관련도 점수: gpt-6-luna가 질문과 후보 50개를 한 번에 읽고 각 청크에 0~10점을 부여해 상위 k개 선정.

Jev: 질문과 청크 1개씩을 jev-latest로 판정한 점수로 정렬. 50회 호출을 8개씩 병렬 처리했다.

Basic / 청크 900자·겹침 0 / k=5 / 기존 후보 20개, LLM·Jev 후보 50개

선정 방식	k=5 Recall 개발 / 추가	운영 표본 시간
기존 hybrid_rerank	.677/.638	약 2.8초
LLM 관련도 점수	.759/.811	평균 17초
Jev 청크별 판정	.736/.692	8병렬 약 1.5초

부록

부록 08 · 하위 질문별 최종 선정 방식 비교

EXP-0009 / 결과, 5.59절 S 후보 발췌 / 원문 표 발췌

> 동일 후보에서 하위 질문별 근거를 분배하면 답할 재료가 늘어나는지 확인한다.

결과 해석

같은 후보에서 k=5 충분 문항이 46개에서 53개로 늘었다.

선정 방식 변경을 지지한다.

하위 질문별 번갈아 선정을 채택했다. 후보 확보와 근거 선정의 역할을 나눠 보았다.

해석의 범위

충분 판정은 답변 정답률이 아니다. 동일 문항으로 설계했고 새 질문 일반화는 미확인이다.

설정·지표 설명

충분 = 선정된 k개 청크에 required_facts(답변에 필요한 사실)가 모두 있는 문항 수. 일부 없으면 부분, 핵심 사실이 없으면 불충분. gpt-6-luna가 청크를 읽고 1회 판정했다.

예: 필요한 사실 4개 중 3개만 있으면 부분. 충분 53은 60문항 중 53문항이라는 뜻이다.

Basic 60문항 / 청크 900자·겹침 0 / 하위 질문 hybrid 병합 S 후보 50개 / k=5·10

같은 S 후보의 선정 방식	k=5 충분	k=10 충분
전체 질문 rerank	46	49
Jev	50	54
하위 질문별 번갈아	53	60

부록 09 · 하위 질문 방식의 후보 수 축소

EXP-0009 / 결과, 후보 수 20 대 50 / 원문 표 발췌

> 후보 수 축소에 따른 품질 손실과 리랭크 시간 절감을 비교한다.

결과 해석

후보 20은 충분 51개, 1.8초.

후보 50은 충분 53개, 4.0초.

구현은 후보 20을 선택했다. 속도 이득과 근거 손실을 함께 기록했다.

해석의 범위

원문은 50 유지가 보수적이라고 판단했다. 시간에는 첫 모델 로딩이 섞였을 가능성이 있어 후속 EXP-0012의 1.40초와 직접 비교하지 않는다.

설정·지표 설명

LLM 하위 질문별로 hybrid 검색한 후보를 합치고, 하위 질문마다 rerank한 순위를 번갈아 담는다. 이 절에서는 최종 k=5와 청킹을 고정하고 후보 수만 줄였다.

충분은 60문항, Recall은 근거 그룹이 있는 56문항 기준이다.

Basic 60문항 / 청크 900자·겹침 0 / hybrid_rerank_subq / k=5 / 후보 50→20개

후보	충분	Recall(56문항)	rerank 평균
20	51	.698	1.8초
50	53	.711	4.0초

부록 10 · 추가 질문에서 검색 방식 재검증

EXP-0010 / 결과, Basic 추가 질문 / 원문 표 발췌

> 개발용 결과의 방식별 우열이 추가 질문에서도 유지되는지 확인한다.

결과 해석

개발용은 rerank 0.677이 가장 높았지만 추가 질문은 naive 0.713이 가장 높았다.

방식 우열을 확정하지 않았다. 한 질문 집합의 최고 점수를 일반화하지 않았다.

해석의 범위

작은 문항 수의 탐색 비교다. 추가 질문에서도 재현되었다고 모든 우위를 주장할 수 없다.

Base / 변경 변수

개발용 질문 / 추가 질문으로 교체, Basic·k=5 유지

측정 지표

방식별 문서 Recall@5 · 개발용/추가 각 28문항

방식	개발용 Recall	추가 질문 Recall
naive	0.651	0.713
hybrid	0.661	0.701
hybrid_rerank	0.677	0.638

부록 11 · k 증가와 문맥 한도 검증

EXP-0005 / 결과, k 비교·토큰 한도 / 원문 표 발췌

> 검색한 근거 증가분을 실제 문맥에도 전달할 수 있는지 확인한다.

결과 해석

k=7은 최대 2,973토큰으로 초과 0건.

k=10은 약 절반~3/4 문항에서 뒤 청크가 빠졌다.

k 확대의 가능성은 확인했지만, 문맥 한도와 답변 품질까지 확인한 뒤 결정하기로 했다.

해석의 범위

토큰은 글자 수 기반 근사다. 이 단계에서는 최종 답변 품질을 측정하지 않았다.

설정·지표 설명

청킹과 후보 20개를 고정하고 최종 k만 늘렸다. 표의 두 값은 개발용 / 추가 질문 순서다.

토큰은 글자 수÷2+1의 근사치. 순서대로 담다가 3,000토큰을 넘으면 해당 청크와 뒤 청크를 제외했다.

Basic / 청크 900자·겹침 0 / hybrid_rerank / 후보 20개 / k=5·7·10 / 한도 3,000

난이도	k=5	k=7	k=10
Basic Recall	.677 / .638	.729 / .701	.790 / .807
Basic 문서 모든그룹	.857 / .714	.929 / .750	.929 / .821
Basic 쪽+인용문 모든그룹	.357 / .500	.464 / .500	.500 / .571

부록

부록 12 · 청크 크기와 k의 공동 조정

EXP-0011 / 결과, 충분·Recall 표 교차 발췌 / 원문 표 발췌

> 작은 청크를 더 많이 넣을 때 검색 점수와 근거 충분함이 함께 개선되는지 본다.

결과 해석

100토큰/k=30은 Recall 0.905지만 충분은 45개.

400토큰/k=10의 충분 50개보다 낮다.

문서 Recall과 답할 재료의 충분함은 함께 오르지 않았다. 극단적 세분화는 보류했다.

해석의 범위

토큰 상한과 글자 상한을 혼동하지 않는다. 충분은 LLM 1회 판정이다.

Base / 변경 변수

900자·k=5 / 400토큰·k=10, 100토큰·k=30 발췌 비교

측정 지표

충분(60문항), 문서 Recall·쪽+인용문 모든그룹(56문항) · Basic

청크 상한 / k	rerank 충분	문서 Recall	쪽+인용문 모든그룹
900자(확정) / 5	46	.658	.429
400 / 10	50	.797	.500
100 / 30	45	.905	.339

부록 13 · 오버랩 효과의 격자 검증

EXP-0014 / 해석 전, 오버랩별 평균표 / 원문 표 발췌

> 여러 청크 크기와 k에서도 오버랩의 품질 이득이 일관되는지 확인한다.

결과 해석

10% 겹침의 Recall 이득은 0.003.

쪽+인용문과 행동 일치율은 오히려 낮았다.

겹침의 일관된 이득을 확인하지 못했다. 검색과 답변 지표를 함께 보고 유지 여부를 판단했다.

해석의 범위

rerank 후보는 22개다. 같은 문항을 반복 평가하지 않았으므로 작은 차이는 확정할 수 없다.

설정·지표 설명

오버랩별 값은 단일 설정이 아니라 8개 크기(100자 간격)×4개 k, 총 32개 조합의 평균이다.
같은 32개 조합에서 겹침 0·10·20%를 비교했다.

900자는 겹침 0% 실험이 없어 공정한 평균 비교에서 제외했다.

Basic / hybrid_rerank / 후보 22개 / 크기 100~800자×k=8·9·10·11 / 한도 3,000

오버랩	문서 Recall	쪽+인용문	행동 일치율
0%	0.754	0.320	0.923
10%	0.757	0.302	0.919
20%	0.745	0.299	0.918

부록 14 · 검색 최고 설정의 실제 답변 품질

EXP-0014 / 결과, RAGAS 4개 지표 중 발췌 / 원문 표 발췌

> 검색 성능 상위 설정의 실제 답변 품질과 검색 지표의 관계를 확인한다.

결과 해석

Faithfulness는 naive 0.941, rerank 0.900.

검색 Recall 순위와 같지 않았다.

검색 점수 상승만으로 최종 답변 품질의 개선을 선언하지 않았다.

해석의 범위

최고 설정을 사후 선택했다. reference·질문 생성 수 등 공식 채점과 다른 근사 조건이다.

설정·지표 설명

크기·겹침·k를 바꾼 312개 방식별 설정에서 각 방식의 문서 Recall 최고값을 하나씩 선택했다. naive .771, hybrid .817, rerank .824이다(rerank k=11도 동률, k=10 선택).

선택한 세 설정으로 만든 답변을 RAGAS로 채점했다. 품질 점수를 보고 고른 세 설정은 아니다.

K: naive 11 / hybrid 11 / rerank 10 / Basic 60문항 / 한도 3,000토큰 / rerank 후보 22개

방식 / 청크 크기 / 겹침	K	Faithfulness	Answer relevancy
naive / 600자 / 10%	11	0.941 (n=59)	0.793 (n=60)
hybrid / 800자 / 0%	11	0.899 (n=59)	0.746 (n=60)
rerank / 800자 / 10%	10	0.900 (n=60)	0.779 (n=60)

부록

부록 15 · 문서 검색 성공과 정확한 근거 포함 비교

EXP-0024 / 결과 10, 쪽·인용문 실패 / 원문 표 발췌

> 문서를 모두 찾은 문항에서도 정확한 쪽·인용문 근거가 빠지는지 진단한다.

결과 해석

rerank도 문서 Recall=1.0인 30문항 중 8문항에서 정확한 근거 그룹을 놓쳤다.

문서 식별과 근거 문장 확보를 분리했다. 실패 문항의 쪽·인용문을 직접 추적해야 한다.

해석의 범위

쪽+인용문 누락은 최종 답변 오답률과 동일하지 않다.

설정·지표 설명

naive: 600자, 겹침 10%, k=11

hybrid: 800자, 겹침 0%, k=11

hybrid_rerank: 800자, 겹침 10%, k=10, 후보 22개

위 설정에서 필요한 book_id를 모두 찾은 문항만 골라 쪽·인용문 누락을 다시 셌다.

Basic 근거 56문항 / 문맥 한도 3,000 / 문서 Recall=1.0인 문항만 선별

방식	문서 Recall 1.0 문항	그중 쪽+인용문 모든그룹 실패	비율
벡터 검색 (naive)	25	14	56%
혼합 검색 (hybrid)	30	13	43%
hybrid_rerank	30	8	27%

부록

부록 16 · 문항 유형별 답변 행동 진단

EXP-0015 / 답변 LLM 요인 1, 문항 유형 / 원문 표 발췌

> 전체 평균에 가려진 되묻기·보류의 행동 오류를 확인한다.

결과 해석

answer는 0.978이지만 clarify는 0.692, abstain은 0.624였다.

평균만 높이는 것보다 되묻기·보류 문항의 근거와 행동 오류를 따로 점검해야 했다.

해석의 범위

같은 60문항을 여러 설정에서 반복한 기록이다. 0.978·0.692·0.624는 소수 셋째 자리 반올림 값이므로 정확한 일치 건수를 역산하지 않는다.

설정·지표 설명

행동 일치율 = 기대 동작과 출력 status가 일치한 답변 수 ÷ 해당 유형의 유효 답변 수.

answer ↔ answered(답변), clarify ↔ needs_clarification(되묻기), abstain ↔ abstained(보류).

예: 되물어야 하는 질문에 answered를 내면 불일치. 답변 내용의 정답률과는 다르다.

Basic 60문항×312개 설정의 답변 / 18,720건 중 오류 9건 제외 / 유효 18,711건

기대 동작	레코드 수	출력 토큰 평균	행동 일치율
answer	14,967	420	0.978
clarify	1,872	367	0.692
abstain	1,872	227	0.624

부록

부록 17 · 문맥 토큰 한도 확대 검증 (진행 중)

EXP-0020 / 가설·배경, 재분석 수치 / 원문 표 발췌

> 검색한 근거가 문맥 한도로 탈락하는 문제와 한도 확대의 효과를 검증한다.

결과 해석

검색한 근거도 최종 문맥에서 빠질 수 있었다.

검색 단계만 튜닝해서는 설명이 부족했다.

문맥 한도 확대와 크기·k의 조합을 검증 중이다. 완료 후 결과와 최종 설정을 갱신한다.

해석의 범위

현재 표는 후속 실험의 배경 수치다. 한도 확대의 효과와 최종 채택값은 아직 확정하지 않았다.

진행 상태와 다음 확인

한도 3,000을 기준으로 3,400·3,800·4,200토큰과 청크 크기·k의 조합을 검증 중이다. 위 표의 탈락 문제를 줄일 수 있는지 검색 지표, 답변 행동, Faithfulness, 시간·토큰을 함께 확인한다.

진행 중 / 아래 표는 기존 3,000토큰 한도의 재분석 / 새 한도 실험의 완료 결과 아님

관찰	사례 수
문맥 한도로 청크가 빠짐	2,050 / 19,440
그중 근거 청크가 빠짐	147
쪽+인용문 모든그룹이 깨짐	57